

**UNIVERSITY OF INFORMATION TECHNOLOGY,
VNU-HCM**

FACULTY OF COMPUTER SCIENCE



FINAL REPORT

TOPIC: HYBRID FOOD SEGMENTATION

Course: CS431

Instructor: *Nguyễn Vinh Tiếp*

Group 9:

No	Name	Student ID
1	Nguyễn Tài Tấn	23521403

Ho Chi Minh City, Ngày 6 tháng 6 năm 2026

Tóm tắt

Báo cáo trình bày pipeline Hybrid Food Segmentation cho bài toán phân đoạn ảnh món ăn. Project so sánh ba kiến trúc supervised: SegFormer-B5 fine-tune trên FoodSeg103 với weighted cross entropy, Mask2Former Swin-Tiny theo hướng mask-level learning, và HDF SwinV2-FPN là mô hình tự xây kết hợp FPN decoder và Food Co-occurrence Module. Pipeline được thiết kế để chạy trên Modal Notebook với GPU H100 hoặc B200, lưu lại đầy đủ artifact sau huấn luyện và tách riêng notebook demo Gradio. Demo trực quan hóa kết quả phân đoạn bằng overlay mask thông qua Gradio, sử dụng artifact SegFormer-B5 vì định dạng Hugging Face dễ tích hợp nhất.

Mục lục

Tóm tắt	1
1 Giới thiệu	4
2 Mục tiêu	4
3 Bài toán và hướng tiếp cận	4
3.1 Vì sao không chỉ dùng classification?	4
3.2 Ý tưởng tổng thể	5
4 Dữ liệu FoodSeg103	6
4.1 Tiền xử lý ảnh và mask	6
5 Mô hình SegFormer-B5	7
5.1 Cách SegFormer hoạt động	7
6 Cấu hình huấn luyện	8
7 Loss, Trainer và metric	9
7.1 Weighted Cross Entropy	9
7.2 WeightedSegformerTrainer	10
7.3 Metric	10
8 Mô hình Mask2Former Swin-Tiny	10
8.1 Cách Mask2Former xử lý dữ liệu	11
8.2 Kiến trúc và forward pass	11
8.3 Loss và training loop	11
8.4 Cấu hình huấn luyện Mask2Former	12
9 Mô hình HDF SwinV2-FPN	12
9.1 Kiến trúc tổng thể	13
9.2 FPN decoder	13
9.3 Food Co-occurrence Module	14
9.4 Loss, metric và training loop	14
9.5 Cấu hình huấn luyện HDF	15
10 So sánh ba mô hình supervised	15
11 Preflight và artifact	16
12 Inference và demo	16

13 Môi trường chạy	17
14 Lỗi đã gặp và cách xử lý	18
15 Đánh giá	18
16 So sánh với các hướng khác	19
17 Failure cases và rủi ro	19
18 Hướng mở rộng	20
19 Checklist chạy project	20
19.1 Notebook train	20
19.2 Notebook demo	20
20 Kết luận	20

1 Giới thiệu

Food segmentation là bài toán dự đoán mask pixel-level cho từng vùng thực phẩm trong ảnh. Với một ảnh món ăn, hệ thống cần xác định mỗi pixel thuộc về lớp nào, ví dụ rice, egg, chicken, duck, tomato, sauce hoặc background. Khác với classification chỉ trả lời “trong ảnh có gì”, segmentation trả lời thêm “mỗi thứ nằm ở đâu và chiếm bao nhiêu diện tích”.

Bài toán này có giá trị thực tế trong ước lượng khẩu phần, nhật ký dinh dưỡng, phân tích lãng phí thực phẩm và các hệ thống tính calories. Vì vùng thức ăn có thể chồng lấn, bị che bởi sauce, hoặc gồm nhiều nguyên liệu nhỏ, project chọn hướng so sánh nhiều kiến trúc supervised: SegFormer-B5, Mask2Former Swin-Tiny và HDF SwinV2-FPN tự xây, nhằm tìm ra baseline tốt nhất cho bài toán food segmentation trên FoodSeg103.

2 Mục tiêu

Pipeline được xây dựng với các mục tiêu chính sau:

- Tải FoodSeg103 trực tiếp từ internet trong notebook thông qua Hugging Face Datasets.
- Fine-tune một mô hình segmentation chuyên biệt cho miền ảnh đồ ăn.
- Lưu checkpoint, processor, label map, training config và metric để tái sử dụng.
- Tách riêng notebook huấn luyện và notebook demo để tránh chạy lại training khi chỉ cần trình diễn.
- So sánh ba kiến trúc supervised: SegFormer-B5, Mask2Former Swin-Tiny và HDF SwinV2-FPN để đánh giá hiệu quả trên FoodSeg103.
- Trực quan hóa kết quả phân đoạn qua Gradio demo với overlay mask.
- Chạy được trên Modal Notebook với GPU mạnh như H100 hoặc B200.

3 Bài toán và hướng tiếp cận

3.1 Vì sao không chỉ dùng classification?

Classification phù hợp khi chỉ cần danh sách nhãn trong ảnh, nhưng không cung cấp thông tin vị trí và diện tích. Với phân tích khẩu phần ăn, diện tích tương đối của từng thành phần là thông tin quan trọng. Segmentation trực quan hơn vì có thể overlay mask lên ảnh gốc, đồng thời cho phép tính tỉ lệ vùng của từng nguyên liệu.

Bảng 1: So sánh classification và segmentation trong bài toán ảnh món ăn.

Tiêu chí	Classification	Segmentation
Đầu ra	Danh sách nhãn	Mask pixel-level
Ước lượng khẩu phần	Khó	Có thể tính diện tích tương đối
Nhiều món chồng lấn	Dễ nhiều	Tách vùng tốt hơn
Demo trực quan	Trung bình	Rất trực quan
Tương tác người dùng	Ít linh hoạt	Có thể refine mask

3.2 Ý tưởng tổng thể

Pipeline được tổ chức theo năm giai đoạn nối tiếp nhau, như minh họa trong Hình 1.

Giai đoạn đầu là **Data**: ảnh món ăn đầu vào được ghép với dataset FoodSeg103 gồm 104 class và ignore index 255.


Giai đoạn thứ hai là **Preprocessing**: ảnh và mask trải qua chuyển đổi RGB, resize đồng bộ, augmentation và label map sanitation để đảm bảo alignment pixel-level trước khi đưa vào training.

Giai đoạn thứ ba là **Models**, gồm ba nhánh song song:

- **Branch A – SegFormer-B5**: fine-tune từ checkpoint `nvidia/segformer-b5-finetuned-ade-640-64` với weighted cross entropy, đầu ra là semantic class map.
- **Branch B – Mask2Former Swin-Tiny**: fine-tune từ checkpoint `facebook/mask2former-swin-tiny` với binary mask labels và class labels theo hướng query-based mask prediction, đạt mIoU 34.30%, mAcc 47.24%, aAcc 80.26%.
- **Branch C – HDF SwinV2-FPN**: mô hình tự xây kết hợp backbone SwinV2-Tiny, FPN Decoder và Food Co-occurrence Module, đầu ra là semantic logits.

Giai đoạn thứ tư là **Post-processing**: logits từ các nhánh được resize về kích thước ảnh gốc, sau đó áp dụng `argmax` để thu về semantic mask cuối cùng.

Giai đoạn cuối là **Evaluation and Demo**: mô hình được đánh giá qua các metric mIoU, mAcc và FWIoU; kết quả được trực quan hóa bằng overlay mask và trình diễn qua Gradio demo sử dụng artifact SegFormer-B5.




Hình 1: Sơ đồ tổng quan pipeline Hybrid Food Segmentation.

4 Dữ liệu FoodSeg103

Project sử dụng dataset EduardoPacheco/FoodSeg103 qua Hugging Face Datasets. Dataset gồm ảnh món ăn và mask segmentation tương ứng. Mỗi sample có ảnh RGB và label mask, trong đó mỗi pixel là một class id.

Notebook cấu hình số class là 104, bao gồm background và 103 nhãn món ăn/nguyên liệu. Label map được lưu thành `id2label.json` và `label2id.json`. Dataset được cache vào `data/hf_cache` để các lần chạy sau nhanh hơn.



Hình 2: Minh họa phân bố dữ liệu/lớp trong project.

4.1 Tiền xử lý ảnh và mask

Transform được viết theo cặp ảnh-mask để giữ alignment pixel-level. Ảnh được chuyển về RGB, còn mask được sanitize: pixel nằm ngoài range class hợp lệ được chuyển thành `ignore_index = 255`. Trong training, notebook dùng random horizontal flip và color jitter nhẹ cho brightness, contrast, color.

Ảnh và mask được resize về `image_size = 768`. Ảnh dùng interpolation bicubic vì ảnh RGB là tín hiệu liên tục. Ngược lại, mask dùng nearest-neighbor vì mask là bản đồ nhãn rời rạc. Nếu resize mask bằng bilinear hoặc bicubic, class id có thể bị nội suy thành giá trị không tồn tại, làm hỏng nhãn segmentation.

5 Mô hình SegFormer-B5

Mô hình supervised chính là:

`nvidia/segformer-b5-finetuned-ade-640-640`


SegFormer là kiến trúc segmentation dựa trên Transformer encoder và MLP decoder. Phiên bản B5 là cấu hình lớn, phù hợp khi có GPU H100/B200. Checkpoint gốc được fine-tune trên ADE20K với 150 class, trong khi FoodSeg103 có 104 class. Vì vậy phần classifier head không khớp và được reinitialize từ 150 sang 104 class.

Đây không phải lỗi, mà là cơ chế transfer learning tiêu chuẩn: encoder vẫn tận dụng visual features tổng quát từ checkpoint pretrained, còn classifier head học lại không gian nhãn food-specific của FoodSeg103.

5.1 Cách SegFormer hoạt động

SegFormer gồm hai phần chính: Transformer encoder phân cấp và MLP decoder nhẹ. Ảnh đầu vào trước hết được chia thành các patch và đưa qua encoder để trích xuất đặc trưng ở nhiều tỉ lệ khác nhau. Các tầng sâu hơn học thông tin ngữ nghĩa mạnh hơn, trong khi các tầng nông hơn giữ lại chi tiết không gian cần thiết cho biên mask. Sau đó decoder gom các đặc trưng đa tỉ lệ, đưa về cùng kích thước, kết hợp chúng và dự đoán logits cho từng class tại mỗi vị trí.

Trong bài toán FoodSeg103, logits đầu ra có 104 channel tương ứng với 104 class. Với mỗi pixel, mô hình chọn class có logit lớn nhất bằng phép `argmax`. Vì logits của SegFormer thường có độ phân giải thấp hơn ảnh gốc, project resize logits về kích thước mask trước khi tính loss và metric.



Hình 3: Minh họa cách hoạt động của SegFormer: ảnh đầu vào, encoder đa tỉ lệ, MLP decoder và semantic mask đầu ra.

Bảng 2: Khác biệt label space giữa ADE20K và FoodSeg103.

Thành phần	ADE20K checkpoint	FoodSeg103 run
Số class	150	104
Decoder classifier weight	[150, 768, 1, 1]	[104, 768, 1, 1]
Encoder	Pretrained	Load lại từ checkpoint
Classifier head	Không khớp	Reinitialize
Ý nghĩa	Visual features tổng quát	Class food-specific

6 Cấu hình huấn luyện

Cấu hình hiện tại trong file `foodseg_hybrid_sam31_modal.ipynb` được tóm tắt ở Bảng 3.

Bảng 3: Training config chính.

Tham số	Giá trị
Dataset	EduardoPacheco/FoodSeg103
Model	nvidia/segformer-b5-finetuned-ade-640-640
Image size	768
Number of labels	104
Ignore index	255
Learning rate	6e-5
Weight decay	0.01
LR scheduler	cosine
Warmup ratio	0.06
Optimizer	adamw_torch_fused nếu có CUDA
Precision	BF16 nếu GPU hỗ trợ

Notebook mặc định chạy full train trên H100. Có thể đổi preset bằng environment variable GPU_PRESET=b200 để tăng batch size và số epoch khi muốn chạy mạnh hơn.

Bảng 4: Preset GPU trong notebook.

Preset	Batch train	Batch eval	Epochs
h100	8	4	12
b200	16	8	20

7 Loss, Trainer và metric

7.1 Weighted Cross Entropy

FoodSeg103 có phân bố class không đều: background và các món phổ biến thường chiếm nhiều pixel hơn, trong khi các nguyên liệu nhỏ như herbs, sauce, onion hoặc mushroom có diện tích rất nhỏ. Nếu dùng cross entropy thường, mô hình dễ thiên về các class lớn và bỏ qua class hiếm.

Notebook ước lượng class frequency từ một số sample train, sau đó tính weight theo hướng inverse-log frequency. Background được giới hạn weight để tránh mô hình quá thiên về nền. Loss cuối cùng có dạng:

$$\mathcal{L} = \text{CE}(\text{logits}, \text{labels}, \text{weight} = \text{class_weights}, \text{ignore_index} = 255)$$

Chi tiết hơn, với một pixel i , logit của class c được ký hiệu là $z_{i,c}$. Xác suất dự đoán sau softmax là:

$$p_{i,c} = \frac{\exp(z_{i,c})}{\sum_{k=1}^C \exp(z_{i,k})}$$

Trong đó $C = 104$ là số class của FoodSeg103. Nếu nhãn thật tại pixel i là y_i , cross entropy thông thường tại pixel đó là:

$$\ell_i = -\log(p_{i,y_i})$$

Với weighted cross entropy, mỗi class y_i có thêm trọng số w_{y_i} , nên loss tại pixel trở thành:

$$\ell_i = -w_{y_i} \log(p_{i,y_i})$$

Loss cuối cùng trên một batch là trung bình trên các pixel hợp lệ, bỏ qua các pixel có nhãn `ignore_index = 255`:

$$\mathcal{L} = \frac{1}{|\Omega|} \sum_{i \in \Omega} -w_{y_i} \log(p_{i,y_i})$$

Trong đó $\Omega = \{i \mid y_i \neq 255\}$ là tập các pixel được dùng để tính loss. Nhờ hệ số w_{y_i} , các class hiếm hoặc có diện tích nhỏ nhận tín hiệu học mạnh hơn, giúp giảm tình trạng mô hình chỉ ưu tiên background và các món phổ biến.

7.2 WeightedSegformerTrainer

Notebook dùng subclass `WeightedSegformerTrainer` thay vì chỉ dùng loss mặc định của `Hugging Face Trainer`. Lý do là output logits của `SegFormer` thường có resolution nhỏ hơn label mask, nên cần resize logits về kích thước label trước khi tính weighted cross entropy.

Flow tính loss:

$$image \rightarrow logits_{lowres} \rightarrow resize(logits) \rightarrow CE(logits, mask)$$

Interpolation cho logits dùng bilinear vì logits là giá trị liên tục. Điều này khác với mask, nơi cần nearest-neighbor để giữ class id rời rạc.

7.3 Metric

Metric chính là mean Intersection over Union. Prediction được lấy bằng `argmax` trên channel class. Logits được resize về kích thước label trước khi tính metric, và pixel có nhãn 255 bị bỏ qua. Notebook chọn `metric_for_best_model = mean_iou` và bật `load_best_model_at_end=True` để lưu model tốt nhất theo validation mIoU.

8 Mô hình Mask2Former Swin-Tiny

Ngoài `SegFormer-B5`, project bổ sung notebook `nd-mask2former.ipynb` để thử một kiến trúc segmentation hiện đại hơn theo hướng mask-level. Mô hình được dùng là:

`facebook/mask2former-swin-tiny-ade-semantic`

Mask2Former là mô hình universal segmentation, có thể dùng cho semantic segmentation, instance segmentation và panoptic segmentation. Điểm khác biệt quan trọng so với SegFormer là Mask2Former không chỉ xem bài toán như phân loại từng pixel độc lập. Thay vào đó, mô hình dự đoán một tập các mask candidate và gán class cho từng mask. Cách tiếp cận này giúp mô hình học trực tiếp ở mức vùng, phù hợp với bài toán món ăn vì mỗi nguyên liệu thường là một vùng có hình dạng rõ ràng nhưng biên phức tạp.

8.1 Cách Mask2Former xử lý dữ liệu

FoodSeg103 cung cấp label map, trong đó mỗi pixel là một class id. Với SegFormer, label map này có thể đưa gần như trực tiếp vào loss sau khi resize đúng cách. Với Mask2Former, notebook dùng Mask2FormerImageProcessor để chuyển label map thành các thành phần phù hợp với mask-level learning:

- `pixel_values`: tensor ảnh sau resize và normalize.
- `pixel_mask`: mask đánh dấu vùng ảnh hợp lệ sau padding/resize.
- `mask_labels`: danh sách các binary mask ứng với từng class xuất hiện trong ảnh.
- `class_labels`: danh sách class id tương ứng với các binary mask đó.

Vì mỗi ảnh có số lượng class xuất hiện khác nhau, `mask_labels` và `class_labels` không thể stack thành một tensor cố định đơn giản. Do đó notebook phải viết `collate_fn` riêng: `pixel_values` và `pixel_mask` được stack, còn `mask_labels` và `class_labels` được giữ dưới dạng list. Đây là lý do DataLoader của Mask2Former phức tạp hơn SegFormer.

8.2 Kiến trúc và forward pass

Checkpoint Mask2Former dùng Swin-Tiny làm backbone để trích xuất đặc trưng ảnh. Sau backbone, pixel decoder và transformer decoder tạo ra các query biểu diễn các vùng tiềm năng trong ảnh. Mỗi query sinh hai đầu ra chính: một mask logit và một phân phối class. Khi train, mô hình so khớp các query dự đoán với ground truth mask thông qua matching, rồi tính loss trên mask và class.

Trong notebook, model được load bằng:

```
Mask2FormerForUniversalSegmentation.from_pretrained(...,
                                                    ignore_mismatched_sizes=True)
```

Tham số `ignore_mismatched_sizes=True` là cần thiết vì checkpoint gốc được học trên ADE20K, còn FoodSeg103 có 104 class. Tương tự SegFormer, phần backbone vẫn tận dụng pretrained visual features, còn phần head/classifier được điều chỉnh lại cho label space của FoodSeg103.

8.3 Loss và training loop

Mask2Former tự tính loss trong forward pass khi truyền `mask_labels` và `class_labels`. Loss tổng hợp gồm nhiều thành phần, trong đó quan trọng nhất là:

- Classification loss để dự đoán đúng class của từng mask query.
- Mask loss để pixel trong mask dự đoán khớp với mask thật.
- Dice loss để tối ưu độ chồng lấp vùng, đặc biệt hữu ích khi class có diện tích nhỏ.
- Matching loss để gán các query dự đoán với ground truth mask theo cách tối ưu.

Training loop của notebook là PyTorch thuần. Với mỗi batch, notebook đưa `pixel_values`, `mask_labels` và `class_labels` lên GPU, gọi model, lấy `outputs.loss`, sau đó backpropagation và cập nhật AdamW. Sau mỗi epoch, notebook chuyển prediction về semantic map bằng `post_process_semantic_map`, resize về kích thước mask gốc, rồi tính mIoU trên validation.

8.4 Cấu hình huấn luyện Mask2Former

Bảng 5: Training config của Mask2Former.

Tham số	Giá trị
Notebook	<code>nd-mask2former.ipynb</code>
Dataset	EduardoPacheco/FoodSeg103
Checkpoint	facebook/mask2former-swin-tiny-ade-semantic
Number of labels	104
Image size	256
Batch size	8
Learning rate	1e-4
Min learning rate	1e-6
LR drop factor	0.5
LR patience	1
Early stop patience	4
Epochs tối đa	50
Checkpoint lưu	<code>mask2former_best_model.pth</code>

Kết quả tốt nhất của Mask2Former đạt mIoU 34.30%, mAcc 47.24% và aAcc 80.26% trên validation. So với SegFormer-B5 trong cấu hình hiện tại, Mask2Former đạt mIoU cao hơn, cho thấy hướng mask-level learning là một baseline mạnh cho FoodSeg103. Tuy nhiên, model này cũng có nhược điểm là pipeline dữ liệu và loss phức tạp hơn, artifact hiện chỉ lưu dạng `.pth` nên chưa tiện đưa thẳng vào demo Gradio như artifact Hugging Face của SegFormer.

9 Mô hình HDF SwinV2-FPN

Notebook `nd-modal (3).ipynb` thử một mô hình tự xây tên HDF cho FoodSeg103. Đây là phần giúp project có đóng góp riêng ngoài việc fine-tune model pretrained. HDF kết hợp ba ý tưởng: backbone SwinV2 để học đặc trưng mạnh, FPN decoder để hợp nhất feature đa tỉ lệ, và Food Co-occurrence Module để học quan hệ đồng xuất hiện giữa các class món ăn.

9.1 Kiến trúc tổng thể

HDF gồm ba khối chính:

- **SwinV2 Tiny backbone**: trích xuất feature phân cấp từ ảnh đầu vào bằng `timm.create_model`.
- **FPN decoder**: đưa feature từ nhiều tầng về cùng độ phân giải và kết hợp chúng theo hướng top-down.
- **Food Co-occurrence Module**: học ma trận quan hệ giữa 104 class và dùng quan hệ đó để hiệu chỉnh logits.

Backbone được tạo bằng:

```
timm.create_model('swinv2_tiny_window16_256', pretrained=True,  
                  features_only=True, dynamic_img_size=True)
```

Vì output feature của `timm` có thể ở dạng NHWC, notebook đổi trục sang NCHW bằng `permute(0, 3, 1, 2)` trước khi đưa vào decoder. Đây là chi tiết kỹ thuật quan trọng; nếu không đổi đúng layout tensor, convolution trong FPN sẽ nhận sai channel.

9.2 FPN decoder

FPN decoder nhận bốn feature map (s_1, s_2, s_3, s_4) từ SwinV2. Feature sâu nhất s_4 có ngữ nghĩa mạnh nhưng độ phân giải thấp; feature nông hơn như s_1 giữ chi tiết không gian tốt hơn. Decoder dùng lateral convolution 1×1 để đưa các feature về cùng số channel, sau đó upsample và cộng dồn:

$$p_4 = L_4(s_4)$$

$$p_3 = L_3(s_3) + \text{Upsample}(p_4)$$

$$p_2 = L_2(s_2) + \text{Upsample}(p_3)$$

$$p_1 = L_1(s_1) + \text{Upsample}(p_2)$$

Sau đó, `cls_head` dùng convolution 1×1 để sinh logits 104 class. Logits được upsample về kích thước ảnh đầu vào bằng bilinear interpolation trước khi đưa qua Food Co-occurrence Module.

9.3 Food Co-occurrence Module

Điểm riêng của HDF là `FoodCoOccurrenceModule`. Module này học một ma trận $\mathbf{A} \in R^{104 \times 104}$, biểu diễn quan hệ mềm giữa các class. Sau softmax theo từng hàng, ma trận này cho biết class này nên nhận thêm tín hiệu từ class nào khác.

Với logits ban đầu $Z \in R^{B \times C \times H \times W}$, notebook flatten logits theo không gian, nhân với ma trận quan hệ $\mathbf{A}$, rồi reshape lại thành feature map. Phần feature quan hệ này đi qua một mapping 1×1 convolution và được cộng lại vào logits:

$$Z' = Z + f(Z\mathbf{A})$$

Ý tưởng này hợp với food segmentation vì các món/nguyên liệu không xuất hiện hoàn toàn độc lập. Ví dụ, rice thường đi cùng chicken duck, sauce thường đi cùng món chính, lettuce thường đi cùng salad hoặc sandwich. Nếu học được quan hệ này, mô hình có thêm tín hiệu global để giảm một số nhầm lẫn ở vùng nhỏ hoặc vùng bị che khuất.

9.4 Loss, metric và training loop

HDF dùng `CrossEntropyLoss(ignore_index=255)`. Với mỗi pixel hợp lệ, mô hình dự đoán phân phối 104 class và loss phạt class dự đoán sai. Khác với SegFormer-B5 trong pipeline chính, bản HDF hiện dùng cross entropy thường, chưa có class weight. Đây là một hạn chế vì FoodSeg103 có phân bố class không đều; các class nhỏ hoặc hiếm có thể bị học yếu hơn.

Metric chính là mIoU. Notebook tính intersection và union bằng `torch.bincount` trên các pixel hợp lệ:

$$IoU_c = \frac{TP_c}{TP_c + FP_c + FN_c}$$

$$mIoU = \frac{1}{|C_{valid}|} \sum_{c \in C_{valid}} IoU_c$$

Sau mỗi epoch, notebook đánh giá trên validation, cập nhật `ReduceLROnPlateau` theo mIoU và lưu checkpoint nếu mIoU tốt hơn. Nếu mIoU không cải thiện quá số lần `patience`, notebook kích hoạt early stopping.

9.5 Cấu hình huấn luyện HDF

Bảng 6: Training config của HDF SwinV2-FPN.

Tham số	Giá trị
Notebook	nd-modal (3).ipynb
Backbone	swinv2_tiny_window16_256
Decoder	FPN decoder, feature dim 256
Module bổ sung	Food Co-occurrence Module
Number of labels	104
Image size	256
Batch size	16
Epochs tối đa	50
Learning rate	6e-4
Optimizer	AdamW
Loss	CrossEntropyLoss(ignore_index=255)
Scheduler	ReduceLROnPlateau, mode max theo mIoU
Patience	3
Checkpoint lưu	hdf_swin_best_model.pth

Kết quả đánh giá cuối của HDF đạt mIoU 33.91%, mAcc 43.38% và aAcc 77.94%. Kết quả này thấp hơn Mask2Former một chút nhưng cao hơn SegFormer-B5 trong bảng hiện tại. Điểm đáng chú ý là HDF là mô hình tự thiết kế, nên kết quả này cho thấy hướng SwinV2-FPN + co-occurrence có tiềm năng. Nếu tiếp tục phát triển, HDF nên được bổ sung weighted loss hoặc focal loss, tăng image size, lưu thêm config/label map/metrics JSON và thử khởi tạo Food Co-occurrence Module từ ma trận đồng xuất hiện thống kê trong EDA.

10 So sánh ba mô hình supervised

Bảng 7: So sánh SegFormer-B5, Mask2Former và HDF trên FoodSeg103.

Model		mIoU	mAcc	aAcc	Image size	Vai trò trong project
SegFormer-B5 weighted CE	+	27.81%	40.86%	–	768	Pipeline chính, artifact tốt cho demo
Mask2Former Tiny	Swin-	34.30%	47.24%	80.26%	256	Baseline mask-level mạnh
HDF SwinV2-FPN FCM	+	33.91%	43.38%	77.94%	256	Mô hình tự xây, có co-occurrence

Bảng 7 cho thấy Mask2Former đạt mIoU cao nhất trong các kết quả đã chạy, còn HDF đạt kết quả cạnh tranh dù là mô hình tự xây. SegFormer-B5 vẫn giữ vai trò pipeline chính vì notebook

đã hoàn thiện artifact theo chuẩn Hugging Face, có `best_model.zip`, để upload sang notebook demo và để kết hợp với SAM. Nói cách khác, Mask2Former và HDF giúp tăng sức nặng thực nghiệm, còn SegFormer-B5 vẫn là nhánh sản phẩm/demo hoàn chỉnh nhất.

11 Preflight và artifact

Trước khi gọi `trainer.train()`, notebook chạy một cell preflight để giảm rủi ro lỗi shape hoặc lỗi dữ liệu trong training loop. Cell này in GPU đang dùng, preset, số sample, batch size, số epoch và số step; sau đó tạo một batch nhỏ, đưa model và batch lên GPU, forward một lượt và kiểm tra shape logits.

Sau training, notebook lưu toàn bộ artifact vào:

```
outputs/<run_name>/best_model
```

Thư mục này gồm `model weights`, `config.json`, `preprocessor_config.json`, `id2label.json`, `label2id.json`, `eval_metrics.json` và `train_config.json`. Notebook cũng nén thành `best_model.zip` để tải về và upload sang notebook demo.

12 Inference và demo

Khi inference bằng model supervised, hệ thống load `SegformerImageProcessor` và `SegformerForSemanticSegmentation` từ artifact `best_model`. Ảnh đầu vào được preprocess, forward qua model để lấy logits, resize logits về kích thước ảnh gốc, sau đó `argmax` để lấy mask class id. Cuối cùng mask được tô màu bằng palette và overlay lên ảnh gốc.

Notebook demo nằm ở:

```
foodseg_gradio_demo_modal.ipynb
```

Flow sử dụng gồm: train xong tải `best_model.zip`, upload vào notebook demo, giải nén vào `uploaded_best_model`, tự tìm thư mục Hugging Face model hợp lệ, sau đó launch Gradio với `share=True`.



Hình 4: Ảnh đầu vào minh họa trong notebook demo.



Hình 5: Ảnh đầu vào demo.



Hình 6: Kết quả overlay mask.

13 Môi trường chạy

Project chạy trên Modal Notebook. Cell đầu dùng `%uv pip install` để cài nhanh dependency. Các nhóm package chính gồm PyTorch/torchvision với CUDA wheel, transformers, datasets, evaluate, accelerate, huggingface_hub, hf_transfer, safetensors, matplotlib, opencv-python-h và tensorboard.

FoodSeg103 là dataset public nên thường không cần token. Notebook hỗ trợ đọc token từ HF_TOKEN hoặc HUGGINGFACE_HUB_TOKEN, hoặc nhập qua getpass để tránh hiển thị token nếu cần truy cập model có gated access.

14 Lỗi đã gặp và cách xử lý

Bảng 8: Một số lỗi kỹ thuật và hướng xử lý.

Hiện tượng	Nguyên nhân	Cách xử lý
<code>classifier.weight MISMATCH</code>	ADE20K có 150 class, FoodSeg103 có 104 class	Bình thường, reinitialize head
Gradient checkpointing không support	Build SegFormer hiện tại không hỗ trợ	Kiểm tra capability rồi skip
HF login inactive	Chưa set token	Không ảnh hưởng dataset public; chỉ cần token nếu dùng model gated
OOM	Batch hoặc image size lớn	Giảm batch hoặc image size
Mask class lạ	Resize mask sai interpolation	Dùng nearest-neighbor cho mask

15 Đánh giá

Sau khi huấn luyện trên FoodSeg103, mô hình được đánh giá bằng các metric phổ biến cho semantic segmentation. Kết quả chính được trình bày trong Bảng 9. Với food segmentation, cần đọc các metric này cùng với kết quả định tính vì một con số duy nhất không luôn phản ánh đầy đủ chất lượng mask trong demo.

Bảng 9: Kết quả đánh giá trên FoodSeg103.

Metric	Giá trị	Ghi chú
Mean IoU	27.81%	Tính cả background
Mean IoU không tính background	27.21%	Chỉ tính các lớp món ăn
Mean Accuracy	40.86%	Trung bình theo từng class
Frequency-Weighted IoU	65.53%	Metric chính của project

Mean IoU đạt 27.81% khi tính cả background và 27.21% khi bỏ background. Hai giá trị này khá gần nhau, cho thấy background không phải yếu tố duy nhất kéo kết quả lên hoặc xuống. Mean IoU là metric nghiêm khắc vì mỗi class được xem gần như ngang nhau khi lấy trung bình. Trong FoodSeg103 có nhiều class hiếm, diện tích nhỏ hoặc dễ nhầm với class khác, nên chỉ cần mô hình dự đoán kém trên các class này thì mIoU trung bình sẽ giảm rõ rệt.

Mean Accuracy đạt 40.86%, nghĩa là nếu xét trung bình theo class, mô hình dự đoán đúng một phần đáng kể pixel của mỗi lớp nhưng vẫn còn nhiều lỗi ở các lớp khó. Chỉ số này thường cao hơn Mean IoU vì accuracy chỉ đo tỉ lệ pixel đúng trên vùng của class, trong khi IoU phạt cả false positive và false negative. Vì vậy IoU phản ánh chất lượng mask chặt chẽ hơn, đặc biệt trong trường hợp biên mask chưa khớp hoặc mô hình dự đoán dư vùng.

Frequency-Weighted IoU đạt 65.53% và được chọn làm metric chính vì nó có tính đến tần suất xuất hiện của từng class. Các lớp phổ biến hoặc chiếm nhiều pixel có ảnh hưởng lớn hơn

đến kết quả cuối. Con số này cao hơn Mean IoU khá nhiều vì mô hình thường học tốt hơn trên background và các món/nguyên liệu xuất hiện thường xuyên. Nói cách khác, FWIoU cho thấy chất lượng tổng thể trên pixel toàn dataset tương đối ổn, còn Mean IoU cho thấy mô hình vẫn cần cải thiện ở các class hiếm và vùng nhỏ.

Sự chênh lệch giữa FWIoU 65.53% và Mean IoU khoảng 27% là hiện tượng hợp lý với FoodSeg103. Dataset có phân bố lớp không đều, nhiều món có hình dạng nhỏ, bị trộn lẫn hoặc bị che bởi sauce. Do đó mô hình có thể phân đoạn tốt các vùng lớn và phổ biến, nhưng vẫn gặp khó với các nguyên liệu ít xuất hiện. Đây là lý do project sử dụng weighted cross entropy để tăng tín hiệu học cho các class hiếm, đồng thời thử nghiệm nhiều kiến trúc để tìm hướng cải thiện mIoU tổng thể.

16 So sánh với các hướng khác

Bảng 10: So sánh hướng hybrid với một số lựa chọn khác.

Hướng	Ưu điểm	Nhược điểm
Classification	Dễ train, nhẹ	Không có mask, khó đo khẩu phần
SegFormer supervised	Có class mask rõ, benchmark được	Cần labeled dataset
Mask2Former	Học ở mức mask, kết quả mIoU tốt	DataLoader/loss phức tạp, artifact demo chưa tiện bằng SegFormer
HDF SwinV2-FPN	Có đóng góp kiến trúc tự xây, học quan hệ đồng xuất hiện	Cần tối ưu thêm imbalance và lưu artifact đầy đủ hơn

Project chọn hướng supervised thay vì các phương pháp open-vocab hoặc prompt-based vì FoodSeg103 là benchmark theo class cố định, cần đo mIoU trên 104 class xác định. Ba kiến trúc supervised được thử nghiệm đại diện cho ba hướng khác nhau: pixel-level classification (SegFormer), mask-level learning (Mask2Former) và kiến trúc tự xây có module học quan hệ class (HDF), từ đó có cơ sở thực nghiệm để so sánh và chọn nhánh demo phù hợp nhất.

17 Failure cases và rủi ro

Food segmentation khó vì ảnh món ăn có nhiều yếu tố gây nhiễu: nhiều nguyên liệu trộn lẫn, sauce che phủ bề mặt, nguyên liệu nhỏ như hành hoặc rau thơm, texture giống nhau như cơm và khoai nghiền, ánh sáng/góc chụp phức tạp, và label dataset không đủ chi tiết cho mọi món ăn Việt Nam.

Một số rủi ro kỹ thuật của pipeline gồm dataset download chậm hoặc đổi schema, phiên bản transformers thay đổi API TrainingArguments, batch size phụ thuộc VRAM thực tế, mean IoU bị ảnh hưởng mạnh bởi class hiếm, và Gradio demo chậm ở lần đầu do load model từ artifact.

18 Hướng mở rộng

Sau khi có mask, project có thể phát triển sang ước lượng calories và khẩu phần. Một hướng là tính tỉ lệ diện tích từng class trong ảnh, kết hợp depth hoặc vật chuẩn để ước lượng volume, sau đó map class sang nutrition database để tính calories và macronutrients.

FoodSeg103 chưa tối ưu riêng cho món Việt Nam, nên có thể cần domain adaptation. Nhóm có thể thu thập thêm ảnh cơm tấm, phở, bún, bánh mì, gỏi cuốn hoặc lẩu, dùng SAM để hỗ trợ annotation nhanh, rồi fine-tune tiếp SegFormer trên tập nhỏ có nhãn Việt Nam.

Với video, SAM 3.1 Object Multiplex có thể dùng để track nhiều object trong một sequence. Use case phù hợp là theo dõi món ăn trong video bếp/canteen, prompt ở frame đầu và propagate mask qua các frame sau để phân tích lượng thức ăn thay đổi theo thời gian.

19 Checklist chạy project

19.1 Notebook train

1. Upload `foodseg_hybrid_sam31_modal.ipynb` lên Modal.
2. Chọn GPU H100 hoặc set `GPU_PRESET=b200` nếu muốn chạy lớn hơn.
3. Run All.
4. Nhập HF token nếu cần SAM checkpoint; có thể skip nếu chỉ train supervised.
5. Đợi train xong và kiểm tra `eval_metrics.json`.
6. Tải `outputs/<run_name>/best_model.zip`.

19.2 Notebook demo

1. Upload `foodseg_gradio_demo_modal.ipynb`.
2. Upload `best_model.zip` vào workspace notebook demo.
3. Run All.
4. Mở link Gradio share.
5. Test chế độ auto supervised segmentation: upload ảnh và kiểm tra overlay mask.

20 Kết luận

Pipeline Hybrid Food Segmentation đóng vai trò như một baseline mạnh và có thể demo được. SegFormer-B5 học segmentation food-specific từ FoodSeg103, trong khi SAM/SAM 3 image API bổ sung khả năng prompt-based segmentation cho trải nghiệm tương tác. SAM 3.1 được giữ ở nhánh video/multi-object tracking để mở rộng đúng hướng. Modal Notebook giúp train trên H100/B200 mà không cần setup local GPU, còn artifact `best_model.zip` tạo cầu nối rõ ràng giữa training notebook và demo notebook.

Bên cạnh pipeline chính, hai notebook bổ sung làm phần thực nghiệm chắc hơn. Mask2Former Swin-Tiny cho thấy hướng mask-level segmentation đạt kết quả tốt trên FoodSeg103. HDF SwinV2-FPN cho thấy mô hình tự thiết kế có thể cạnh tranh nếu kết hợp backbone mạnh, FPN decoder và Food Co-occurrence Module. Điểm mạnh nhất của project là cân bằng giữa benchmark supervised, so sánh nhiều kiến trúc và khả năng tương tác linh hoạt. Đây là nền tảng hợp lý để phát triển tiếp các ứng dụng dinh dưỡng, phân tích khẩu phần và demo phân đoạn món ăn theo prompt.

Tài liệu

- [1] Xie, E., Wang, W., Yu, Z., Anandkumar, A., Alvarez, J. M., and Luo, P. SegFormer: Simple and Efficient Design for Semantic Segmentation with Transformers. NeurIPS, 2021.
- [2] FoodSeg103 dataset on Hugging Face, <https://huggingface.co/datasets/EduardoPacheco/FoodSeg103>.
- [3] Hugging Face Transformers documentation, <https://huggingface.co/docs/transformers>.
- [4] Kirillov, A. et al. Segment Anything. ICCV, 2023.
- [5] Zhou, B., Zhao, H., Puig, X., Fidler, S., Barriuso, A., and Torralba, A. Scene Parsing through ADE20K Dataset. CVPR, 2017.
- [6] Cheng, B., Misra, I., Schwing, A. G., Kirillov, A., and Girdhar, R. Masked-attention Mask Transformer for Universal Image Segmentation. CVPR, 2022.
- [7] Liu, Z. et al. Swin Transformer V2: Scaling Up Capacity and Resolution. CVPR, 2022.