

Food Segmentation

SegFormer-B5 + Mask2Former + HDF SwinV2-FPN

CS431.Q21 Các kĩ thuật học sâu và ứng dụng

Họ và tên	MSSV
Nguyễn Tài Tấn	23521403

GVHD: **Nguyễn Vinh Tiệp**

Ngày 6 tháng 6 năm 2026

Bài toán food segmentation là gì?

Với một ảnh món ăn, hệ thống cần dự đoán mask pixel-level cho từng vùng thực phẩm.

Đầu vào

Ảnh RGB của món ăn, khay cơm, đĩa salad, buffet, phần ăn bệnh viện, hoặc ảnh người dùng chụp bằng điện thoại.

Đầu ra

Một bản đồ nhãn cùng kích thước với ảnh, trong đó mỗi pixel thuộc về một class như rice, egg, chicken duck, tomato, sauce, hoặc background.

Giá trị ứng dụng

Dùng để ước lượng khẩu phần, tính tỷ lệ nguyên liệu, hỗ trợ nhật ký dinh dưỡng, phân tích lãng phí thực phẩm, và làm nền cho hệ thống tính calories.

Ảnh minh họa Input/Output

Input



Output




```
[{'label': 'biscuit', 'area_pct': 29.08},  
{ 'label': 'coffee', 'area_pct': 8.27}]
```

Dataset: FoodSeg103

Pipeline dùng dataset EduardoPacheco/FoodSeg103 qua Hugging Face Datasets.

- **Đặc điểm:** Dataset gồm ảnh món ăn và mask segmentation đi kèm.
- **Số lượng class: 104** class (bao gồm background và các nhãn nguyên liệu/món ăn).
- **Quản lý nhãn:** Label map được lưu thành hai file `id2label.json` và `label2id.json`.



Hình: Minh họa ảnh gốc và mask segmentation trong FoodSeg103

Khám phá dữ liệu: ảnh và mask

- ▶ Ảnh món ăn đa dạng về góc chụp, ánh sáng và bố cục.
- ▶ Mask ground truth giúp kiểm tra class và biên vùng trước khi train.

Khám phá Trực quan Tập dữ liệu FoodSeg103

Ảnh gốc (Mẫu #2991)



Nhãn Phân Vùng (Ground Truth)



Ảnh gốc (Mẫu #4047)



Nhãn Phân Vùng (Ground Truth)



Ảnh gốc (Mẫu #4916)





Nhãn Phân Vùng (Ground Truth)



Khám phá dữ liệu: phân bố class

FoodSeg103 có phân bố class lệch, nên cần weighted loss và các metric theo class như mIoU/mAcc.




Tiền xử lý ảnh và mask

Transform được viết theo cặp ảnh-mask để giữ alignment pixel-level.

- ▶ Ảnh convert về RGB.
- ▶ Mask được sanitize: pixel ngoài range class sẽ chuyển thành `ignore_index = 255`.
- ▶ Train dùng random horizontal flip.
- ▶ Train dùng color jitter nhẹ: brightness, contrast, color.
- ▶ Ảnh và mask được resize về `image_size = 768`.
- ▶ Ảnh dùng interpolation bicubic; mask dùng nearest-neighbor để không làm hỏng class id.

Kiến trúc tổng quan pipeline


- ▶ Input: ảnh món ăn.
- ▶ Dataset: FoodSeg103.
- ▶ Ba nhánh model: SegFormer, Mask2Former, HDF.
- ▶ Output: semantic mask và metric đánh giá.



Model Supervised: Kiến trúc SegFormer-B5

Đặc điểm kiến trúc

- **Cơ chế cốt lõi:** Kết hợp *Hierarchical Transformer Encoder* (trích xuất đặc trưng đa quy mô) và *Lightweight MLP Decoder* (khôi phục bản đồ phân đoạn).
- **Cải tiến Encoder:**
 - *Efficient Self-Attention*: Giảm tối đa chi phí tính toán.
 - *Mix-FFN*: Học thông tin vị trí không cần Positional Encoding.
- **Fine-tuning:** Chuyển đổi đầu ra từ checkpoint ADE20K (150 lớp) sang **104 lớp** của FoodSeg103.



Hình: Sơ đồ tổng quan kiến trúc SegFormer

SegFormer: Training Configuration & Validation Results

Bảng: Bảng thiết lập tham số hình học và siêu tham số tối ưu hóa


Tham số hệ thống	Giá trị cấu hình
Dataset	EduardoPacheco/FoodSeg103
Model Backbone	nvidia/segformer-b5-finetuned-ade-640-640
Image size ($H \times W$)	768 $\times$ 768
Number of labels	104
Ignore index	255
Learning rate	6e-5
Weight decay	0.01
LR scheduler	Cosine Annealing
Warmup ratio	0.06
Optimizer	adamw_torch_fused
Precision	Mixed Precision (BF16)

Bảng: Kết quả đánh giá tốt nhất trên tập dữ liệu Validation

Model Supervised: Kiến trúc Mask2Former

Đặc điểm kiến trúc

- ▶ **Cấu trúc vạn năng:** Giải quyết đồng thời các tác vụ Semantic, Instance và Panoptic segmentation trên cùng một framework duy nhất.
- ▶ **Cơ chế Mask Classification:** Thay vì phân loại từng pixel, mô hình dự đoán tập hợp các *Binary Masks* thông qua các *Mask Queries* và cơ chế tương khớp *Bipartite Matching*.
- ▶ **Tối ưu thành phần:** Tích hợp backbone Swin-Tiny nhỏ gọn cùng hệ thống *Pixel-level*.



Hình: Cơ chế phân đoạn dựa trên Mask-Classification

Mask2Former: Pipeline Configuration & Validation Results

Thiết lập huấn luyện

- ▶ **Dataset:** EduardoPacheco/FoodSeg103
- ▶ **Image size:** 256 × 256
- ▶ **Batch size:** 8
- ▶ **Max epochs:** 50 (Early stopping patience: 4)
- ▶ **Learning rate:** 1e-4

Cơ chế xử lý & Hàm mất mát

- ▶ **Tiền xử lý:** Mask2FormerImageProcessor phân rã mask nhãn thành các tập hợp binary mask độc lập theo từng class hiện diện.
- ▶ **Hàm tổn thất tổng hợp:** Sự kết hợp đa mục tiêu giữa *Cross-Entropy loss*, *Dice loss* và *Bipartite Matching loss*.

Bảng: Kết quả đánh giá tốt nhất trên tập dữ liệu Validation

mIoU	mAcc	aAcc
34.30%	47.24%	80.26%

Mask2Former: input/output trong notebook


Với mỗi batch, Mask2Former dùng format khác SegFormer vì model học trên tập mask query.

Trường dữ liệu	Vai trò
<code>pixel_values</code>	Tensor ảnh đã resize/normalize để đưa vào backbone Swin
<code>mask_labels</code>	Danh sách binary mask của các class xuất hiện trong ảnh
<code>class_labels</code>	Nhãn class tương ứng với từng binary mask
<code>outputs.loss</code>	Loss tổng hợp do model tự tính trong forward pass

Điểm cần nhấn mạnh: label map FoodSeg103 được processor chuyển thành nhiều binary mask nội bộ.

Backbone & Attention


- **Backbone Swin V2:** Sử dụng chuỗi khối Swin Transformer V2 liên tiếp với cửa sổ dịch chuyển song song (WMSA và SWMSA) giúp nắm bắt toàn diện ngữ cảnh.
- **Scaled Cosine Attention:** Dùng khoảng cách Cosine để ổn định hóa biểu diễn đặc trưng, giảm thiểu sự phụ thuộc vào biên độ của vector kích hoạt (activation).



Cơ chế Scaled Cosine Attention trong khối Swin V2

Cơ chế mã hóa vị trí

- **Khối Log-CPB:** Cơ chế toán học liên tục (*Continuous Position Bias*) giúp giải quyết bài toán thay đổi kích thước ảnh đầu vào.
- **Nguyên lý hoạt động:**
 - Chuyển đổi tọa độ độ khoảng cách sang không gian logarit ($\Delta x, \Delta y \rightarrow \log$).
 - Truyền qua mạng MLP tuyến tính để sinh bias không gian liên tục một cách linh hoạt.



Khối Log-CPB hỗ trợ biến đổi kích thước hình học

HDF: config train trong nd-modal

Thành phần	Giá trị
Dataset	EduardoPacheco/FoodSeg103
Number of labels	104
Image size	256
Batch size	16
Epoch tối đa	50
Learning rate	6e-4
Optimizer	AdamW
Scheduler	ReduceLROnPlateau theo validation mIoU
Early stopping	patience = 3
Checkpoint	hdf_swin_best_model.pth

So sánh metric các model

Model	mIoU	mAcc	aAcc	FWIoU	Ghi chú
SegFormer-B5	27.81%	40.86%	-	65.53%	Baseline supervised chính, image size 768
Mask2Former Swin-Tiny	34.30%	47.24%	80.26%	-	Baseline mask-level/query-based
HDF SwinV2-FPN	33.91%	43.38%	77.94%	-	Mô hình tự xây, có Food Co-occurrence Module

Dấu “-” nghĩa là notebook hiện tại chưa ghi metric đó cho model tương ứng.

Metric segmentation

Không nên chỉ nhìn một metric duy nhất vì mỗi chỉ số phản ánh một góc khác nhau của chất lượng mask.

Metric	Ý nghĩa khi đánh giá food segmentation
mIoU	Đo độ khớp vùng giữa prediction và ground truth theo từng class; phù hợp nhất để so sánh mask.
mAcc	Đo accuracy trung bình theo class; giúp xem model có bỏ quên class nhỏ/hiếm không.
aAcc	Đo accuracy pixel toàn cục; dễ cao nếu model làm tốt background hoặc class lớn.
FWIoU	Có tính đến tần suất pixel; hữu ích nhưng có thể ưu ái class phổ biến.

So sánh hiệu quả phân vùng

Qualitative results giúp nhìn lỗi biên, lỗi class nhỏ và nhầm lẫn giữa nguyên liệu mà metric không thể hiện hết.

So Sánh Hiệu Quả Phân Vùng: Ảnh Gốc vs. Nhân Thực Tế vs. AI HDF Dự Đoán



1. Ảnh Gốc (Input Image)



2. Nhân Chuẩn (Ground Truth)



3. HDF Dự Đoán (Prediction)



So sánh với một số hướng khác

Hướng	Ưu điểm	Nhược điểm
Classification	Dễ train, nhẹ	Không có mask, khó đo khẩu phần
SegFormer supervised	Có class mask rõ, benchmark được	Cần labeled dataset
Mask2Former supervised	Query-based mask prediction, mIoU tốt trên validation	Train phức tạp hơn, image size nhỏ hơn
HDF SwinV2-FPN	Có thiết kế riêng cho co-occurrence món ăn	Cần kiểm chứng thêm bằng metric và qualitative grid
SAM only	Linh hoạt prompt, zero-shot tốt	Không tự nhiên cho fixed-class benchmark
GroundingDINO + SAM	Open-vocab mạnh	Pipeline phức tạp, nhiều ngưỡng
Hybrid SAM SegFormer +	Cân bằng domain learning và promptability	Cần quản lý hai nhánh model

Hướng mở rộng: calories và khẩu phần

Sau khi có mask, có thể xây tiếp bài toán dinh dưỡng.

- ▶ Tính tỷ lệ diện tích từng class trong ảnh.
- ▶ Kết hợp depth/known reference object để ước lượng volume.
- ▶ Map class sang nutrition database để tính calories/macro.
- ▶ So sánh ảnh trước/sau bữa ăn để ước lượng lượng ăn còn lại.
- ▶ Dùng user feedback để sửa mask và cải thiện dữ liệu.

Hướng mở rộng: món ăn Việt Nam

FoodSeg103 không tối ưu riêng cho món Việt, nên có thể cần domain adaptation.

- ▶ Thu thập thêm ảnh cơm tấm, phở, bún, bánh mì, gỏi cuốn, lẩu.
- ▶ Dùng SAM để hỗ trợ annotation nhanh.
- ▶ Fine-tune tiếp SegFormer trên tập nhỏ có nhãn Việt Nam.
- ▶ Tách label theo nguyên liệu hoặc theo món tùy mục tiêu.
- ▶ Xây taxonomy riêng: món, nguyên liệu, nhóm dinh dưỡng.

Kết luận

Pipeline hiện tại có vai trò như một baseline mạnh và có thể demo được:

- ▶ SegFormer-B5 học segmentation food-specific từ FoodSeg103.
- ▶ Mask2Former-Swin-Tiny là baseline supervised thứ hai, đạt **mIoU 34.30%**, **mAcc 47.24%**, **aAcc 80.26%** trên validation.
- ▶ HDF SwinV2-FPN là nhánh tự thiết kế, đạt **mIoU 33.91%**, **mAcc 43.38%**, **aAcc 77.94%**.
- ▶ Demo Gradio hiện tại dùng checkpoint `best_model.zip` để chạy inference trực tiếp.
- ▶ Pipeline tách rõ training và demo, giúp tái sử dụng artifact mà không cần train lại.
- ▶ Modal Notebook giúp train trên GPU cloud thay vì phụ thuộc local GPU.
- ▶ Kết quả hiện tại đóng vai trò bộ baseline để so sánh các kiến trúc food segmentation.

Điểm mạnh nhất của hướng này là cân bằng giữa **benchmark supervised** và **khả năng tương tác linh hoạt**.